

Оценка вероятности дефолта (PD) для металлургических компаний.

Андреев Иван, Андрюхин Борис, Гусева Людмила, Крайнова Софья, Арефьева Софья

I. Введение.

Данная работа посвящена построению модели кредитного скоринга корпоративных клиентов банка из металлургического сектора. Модели оценки вероятности дефолта являются основой современной банковской системы. На их основе банк принимает решение о выдаче кредита клиенту или об отказе в кредитовании. Также PD-модели позволяют банку оценить ожидаемые потери и правильно определить необходимую сумму резервов, чтобы избежать проблем с ликвидностью. В кредитном скоринге корпоративных клиентов очень большую роль играет отрасль деятельности заемщика. Поэтому имеет смысл построение отдельных моделей для каждого экономического сектора.

Оценка кредитного риска промышленных компаний требует прозрачной методики и воспроизводимых исходных данных. Для металлургов это связано с высокой капиталоемкостью, существенной долей постоянных затрат и распространённым использованием заемного финансирования. Изменения ценовой конъюнктуры и спроса отражаются на маржинальности, потребности в оборотном капитале и способности обслуживать долг, что повышает значимость оценки вероятности дефолта.

1. Актуальность.

Металлургия остается одним из значимых промышленных комплексов и ориентирована на внешние и внутренние рынки. Отрасль подвержена цикличности спроса и цен на металлы, а финансовые показатели компаний заметно реагируют на изменения конъюнктуры и стоимости финансирования.

В прикладных задачах кредитного анализа важно использовать модель, которая учитывает специфику отрасли и допускает интерпретацию результатов. Отраслевой подход позволяет соотнести рост PD с изменениями в прибыльности, левередже, ликвидности и фазе промышленного цикла, а также формировать сопоставимые ориентиры для кредитных лимитов, ковенант и триггеров раннего предупреждения.

2. Цель и задачи исследования.

Цель исследования - построить и интерпретировать отраслевую модель вероятности дефолта (PD) для металлургических компаний Российской Федерации, а также определить направления практического применения результатов модели.

Для достижения цели поставлены следующие задачи:

- Обобщить результаты исследований по оценке вероятности дефолта и отбору факторов кредитного риска для капиталоемких отраслей; сформулировать гипотезы о влиянии выбранных показателей на PD.
- Обосновать выбор признаков для моделирования с учетом отраслевой специфики металлургии и экономического смысла показателей.
- Подготовить обучающую выборку, а также определить критерии включения наблюдений, подходы к обработке пропусков и выбросов, а также правила формирования целевой переменной дефолта.
- Оценить модель PD, провести проверку качества и устойчивости результатов, интерпретировать вклад факторов в изменение вероятности дефолта, максимизировать прибыль от кредитования.

3. Краткий обзор отрасли.

Металлургические компании характеризуются значительными инвестициями в основные средства и высокой долей амортизации, что делает показатели долговой нагрузки и покрытия особенно чувствительными к снижению операционной прибыли. При ухудшении ценовой конъюнктуры и спроса снижение выручки может приводить к непропорциональному падению EBITDA и росту долговых метрик.

4. Обзор литературы.

- Финансовые факторы вероятности дефолта

В литературе по моделированию вероятности дефолта корпоративных заемщиков финансовые показатели компании рассматриваются как ключевые детерминанты кредитного риска. Наиболее часто в моделях PD используются показатели прибыльности, ликвидности и долговой нагрузки, так как они напрямую отражают

способность компании обслуживать обязательства и поддерживать финансовую устойчивость.

Так, в статье Verikova и Zubarev (2022) проводится эконометрический анализ факторов банкротства российских компаний обрабатывающей промышленности за период 2012-2020 гг. Авторы используют данные СПАРК-Интерфакс и строят логистические модели, в которых дефолт определяется через начало процедуры банкротства. Полученные результаты показывают, что финансовые показатели рентабельности, ликвидности и деловой активности оказываются статистически значимыми факторами риска. В частности, более высокая рентабельность, измеряемая отношением EBIT к активам, снижает вероятность дефолта. При этом низкая ликвидность и высокая долговая нагрузка, которая отражается через чистую кредиторскую задолженность, увеличивают риск банкротства.

Аналогичные выводы представлены в исследованиях Банка России. В статье Shevelev (2022) финансовые коэффициенты рассматриваются как базовый набор факторов для оценки PD российских компаний. Автор подчёркивает, что именно показатели рентабельности, ликвидности и долговой нагрузки формируют основу моделей вероятности дефолта и сохраняют свою значимость при использовании как классических, так и машинных методов обучения.

Рассмотренные исследования подтверждают, что финансовые показатели являются ключевыми предикторами PD.

- Нефинансовые характеристики компаний

Помимо финансовых показателей, в литературе подчёркивается роль нефинансовых характеристик компании, таких как возраст, организационно-правовая форма, региональная принадлежность и подотраслевые различия. Эти факторы показывают институциональную устойчивость фирмы и особенности её функционирования в конкретной экономической среде.

В работе Verikova и Zubarev (2022) показывают, что возраст компании оказывает устойчивое влияние на вероятность банкротства. Молодые фирмы чаще сталкиваются с финансовыми трудностями и имеют более высокий риск дефолта. Также в работе выявлена значимость институциональных характеристик, связанных со структурой собственности и корпоративного управления.

- Влияние макроэкономической конъюнктуры

Отдельное направление исследований посвящено анализу влияния макроэкономических условий на вероятность дефолта корпоративных заемщиков. Экономические циклы, колебания внешнего спроса и изменения цен на ключевые товары могут оказывать существенное влияние на финансовое положение фирм, особенно в циклических секторах, таких как металлургия.

В исследовании Тотьмяниной (2014) показано, что включение макроэкономических индикаторов существенно повышает объяснительную способность моделей PD. Автор демонстрирует, что такие переменные, как цена нефти, уровень занятости и параметры внешнеторговой деятельности, оказывают статистически значимое влияние на вероятность дефолта, а это подтверждает необходимость учитывать состояние экономики при оценке кредитного риска.

Дополнительное подтверждение роли макросреды можно найти в аналитических материалах Всемирного банка. В публикации Kabundi (2022), посвящённой причинам и последствиям ценовых шоков на промышленные товары, показано, что колебания цен на энергию и металлы оказывают значительное влияние на экономическую активность стран и секторов, ориентированных на экспорт сырьевых товаров. Учитывая, что металлургический сектор тесно связан с движением мировых цен на металлы, данные выводы усиливают аргумент о том, что макроэкономические условия и ценовые шоки должны учитываться при построении моделей вероятности дефолта для предприятий отрасли.

Результаты указанных исследований подтверждают необходимость включения макроэкономических индикаторов в модель вероятности дефолта.

5. Риск-факторы.

На основе обзора литературы для построения модели оценки вероятности дефолта компаний металлургической отрасли были взяты как финансовые показатели самих компаний, так и институциональные характеристики, а также макроэкономические факторы, отражающие состояние промышленного сектора и кредитного рынка. С одной стороны, мы хотели учесть классические параметры, которые являются сигналами дефолта, с другой – учесть специфику металлургии как капиталоемкой и циклической

отрасли, чувствительной к инвестиционному и кредитному циклу. Финансовые показатели используем с лагом в один год, чтобы могли предсказать вероятность дефолта на следующий период.

- Финансовые показатели компании.

a. EBIT_L1 (прибыль до процентов и налогов, лаг 1 год).

EBIT характеризует способность компании генерировать операционную прибыль до учёта структуры финансирования. Для металлургических предприятий это ключевой показатель, так как операционная прибыльность жёстко зависит от загрузки мощностей, цен на сталь/прокат и затрат на сырьё и энергоносители. При низком EBIT компания с высокой долговой нагрузкой быстро становится уязвимой: обслуживание долга перестаёт покрываться операционным потоком, возрастает риск нарушения ковенант и дефолта. Использование величины с лагом в 1 год позволяет учитывать не только мгновенное состояние, но и инерцию ухудшения/улучшения операционной деятельности, что характерно для капиталоемких отраслей, где изменение спроса отражается в отчётности с лагом.

b. Net_profit_L1 (чистая прибыль, лаг 1 год).

Чистая прибыль уже учитывает финансовые расходы, налоги и разовые эффекты. Для металлургов, часто работающих с крупными инвестиционными программами и существенными процентными расходами, именно чистая прибыль позволяет оценить, насколько бизнес устойчив в целом, а не только на уровне операционного результата. Последовательные убытки по чистой прибыли – сигнал о проблемах с обслуживанием долга и ухудшения условий для кредитования в банках и отношений с поставщиками, что повышает вероятность дефолта.

c. Debt_equity_L1 (отношение заемного капитала к собственному, лаг 1 год).

Показатель Debt/Equity отражает структуру капитала и финансовый рычаг. Металлургия – капиталоемкая отрасль с высокой долей заёмного финансирования в период модернизаций, строительства новых мощностей и расширения добычной базы. Высокий рычаг работает в пользу акционеров при благоприятной конъюнктуре рынка (рост цен на металл, высокий экспортный спрос), но резко повышает риск дефолта при рецессии или снижении маржи. Для металлургов избыточная долговая нагрузка особенно критична из-за высокой доли

фиксированных затрат (энергия, труд, амортизация): при падении объёмов производства прибыль падает быстрее выручки, и выплаты по долгу могут быть слишком высокими, что приведет к дефолту.

d. ROA_L1 (рентабельность активов, лаг 1 год).

ROA показывает, насколько эффективно компания использует весь совокупный актив. В металлургии, где основная часть активов - это металлургические комбинаты, печи, прокатные станы, низкий ROA может означать недозагрузку мощностей, избыточные мощности или слабое управление оборотным капиталом. В таких условиях даже при формально высоких продажах предприятие может не генерировать достаточный денежный поток для обслуживания долга, что повышает риск дефолта.

e. ROE_L1 (рентабельность собственного капитала, лаг 1 год).

ROE отражает доходность для собственников с учётом финансового рычага. Для отрасли характерно, что акционеры часто реализуют крупные инвестиционные проекты с расчётом на высокую долгосрочную доходность. Если ROE стабильно низкий или отрицательный, это сигнал либо о неудачных инвестициях, либо о чрезмерном долге, либо о слабой марже. Для кредиторов это важный индикатор, так как компании с ROE на низком уровне находятся под давлением акционеров и могут идти на более рискованные решения, тем самым увеличивая вероятность дефолта.

f. Current_liq_L1 (коэффициент текущей ликвидности, лаг 1 год).

Текущая ликвидность показывает способность погасить краткосрочные обязательства за счёт оборотных активов. У металлургов доля краткосрочных обязательств значительна: краткосрочные кредиты, задолженность поставщикам сырья, обязательства перед транспортными компаниями и т.п. При недостаточной текущей ликвидности компания сталкивается с кассовыми разрывами, задержками платежей и ухудшением условий кредитования. В специфике отрасли это особенно актуально, так как сбой в оплате сырья или услуг логистики быстро отражается на производстве и отгрузках, что усиливает негативную спираль и повышает риск дефолта.

g. Quick_liq_L1 (коэффициент быстрой ликвидности, лаг 1 год).

Быстрая ликвидность очищает оборотные активы от запасов, которые в металлургии могут быть менее мобильными (сырьё, готовый прокат специфических характеристик). Для компаний отрасли важно, насколько быстро они могут конвертировать наиболее ликвидные активы (денежные средства, краткосрочные финансовые вложения, дебиторскую задолженность) в платежи по текущим обязательствам. Низкий коэффициент быстрой ликвидности при высокой долговой нагрузке – индикатор краткосрочного дефолт-риска, особенно в периоды волатильности цен на сырьё и металлопродукцию.

- Нефинансовые характеристики компаний.

- a. Возраст компании (age).*

Возраст отражает степень устоявшейся бизнес-модели, опыт менеджмента и доступ к устойчивым каналам сбыта и финансирования. Для металлургии это особенно важно, так как крупные и средние металлургические предприятия часто работают в рамках долгосрочных контрактов с промышленными потребителями (машиностроение, стройкомпании, экспортные покупатели). Более старые компании, как правило, уже прошли несколько кризисных фаз (девальвации, спад 2008-2009, 2014-2015 и 2020 год) и доказали способность адаптироваться к циклам спроса на металлопродукцию. Молодые фирмы в отрасли, наоборот, чаще ограничены в доступе к финансированию на длительный срок, зависят от одного-двух ключевых контрагентов и потенциально более уязвимы к шокам спроса и цен на сырьё.

- b. Регион (region).*

Во-первых, металлургические предприятия традиционно привязаны к сырьевой базе и транспортной инфраструктуре (наличие железнодорожных узлов, портов, близость к угольным и рудным месторождениям). Различия в логистических затратах и доступе к сырью напрямую влияют на себестоимость и устойчивость компаний. Во-вторых, регионы отличаются по уровню институциональных рисков, налоговых льгот, поддержки со стороны региональных властей и доступу к местному банковскому кредитованию. Регионы с развитой промышленностью, как правило, обеспечивают более стабильный спрос со стороны смежных отраслей и снижают риск дефолта

предприятий в цепочке. Соответственно, регион выступает обобщающим фактором среды, в которой работает металлургическая компания.

с. Организационно-правовая форма (form).

Организационно-правовая форма (ООО, ПАО, АО, КП, ФЮЛ и др.) влияет на структуру корпоративного управления, доступ к рынкам капитала и прозрачность отчётности. Для металлургов это принципиально:

- ПАО и крупные АО чаще имеют доступ к публичным рынкам капитала, более жёсткие требования к раскрытию информации и, как следствие, более высокий контроль со стороны инвесторов и кредиторов.
- ООО и закрытые структуры могут иметь более концентрационную структуру собственности, менее формализованные процедуры управления рисками и большую зависимость от решений ограниченного круга собственников.

d. Принадлежность государству (is_gov).

Признак государственной принадлежности важен, поскольку для крупных государственных металлургических компаний действуют иные ожидания рынка относительно дефолта. Государство может выступать кредитором последней инстанции, обеспечивая поддержку в кризисные периоды (реструктуризация долгов, субсидированные кредиты, госзаказ). Это снижает рыночную вероятность дефолта по сравнению с частными компаниями сопоставимого финансового состояния. Одновременно госкомпании могут реализовывать социально и политически мотивированные проекты с более низкой доходностью, что влияет на показатели рентабельности, поэтому само наличие признака помогает корректно интерпретировать такие случаи.

e. Подотрасль (ttype).

Переменная ttype отражает специализацию внутри металлургического комплекса: производство чугуна и стали, прокат, выпуск строительных металлических конструкций, обработка металла и т.д. Различные подотрасли по-разному чувствительны к фазе строительного цикла, к инвестициям в инфраструктуру, к экспорту. Например, производители строительных металлоконструкций больше завязаны на внутренний строительный рынок и госзаказы, производители плоского проката и полуфабрикатов сильнее

ориентированы на экспорт и мировые цены. Волатильность выручки, маржа и структура заказов у этих групп различаются, соответственно, различается и оценка вероятности дефолта.

- Макроэкономические факторы.

a. Среднегодовой PMI производственного сектора.

PMI промышленности является опережающим индикатором деловой активности в обрабатывающем секторе. Для металлургов он очень важен, так как сталь и металлопродукция – базовый вход для большинства промышленных отраслей: машиностроения, строительства, ТЭК. Снижение PMI сигнализирует о сокращении заказов и загрузки мощностей промышленности, что обычно приводит к снижению спроса на металлы и давлению на цены. В такие периоды риск дефолта металлургических компаний возрастает, поскольку падает выручка, ухудшаются операционные потоки, и при той же долговой нагрузке вероятность неплатежей выше.

b. Среднегодовой курс USD/RUB.

Для металлургической отрасли валютный курс может влиять по-разному. С одной стороны, многие крупные металлурги ориентированы на экспорт, продавая продукцию за валюту. Ослабление рубля повышает рублёвую выручку экспортёров и частично компенсирует негативные ценовые шоки на мировом рынке. С другой стороны, часть затрат (оборудование, лицензии, сервис, иногда сырьё и логистика) может быть привязана к валюте. Кроме того, валютный курс влияет на общую макроэкономическую и финансовую стабильность: резкая девальвация ведёт к скачку инфляции, ужесточению монетарной политики и росту ставок.

c. Средние процентные ставки по кредитам до 1 года для обрабатывающего сектора.

Этот показатель отражает стоимость краткосрочного заимствования для промышленных компаний. Металлургия активно использует краткосрочные кредиты для финансирования оборотного капитала (запасы руды, угля,

металлолома, дебиторская задолженность). Рост средних ставок напрямую увеличивает финансовые расходы, особенно для компаний с высокими задолженностями. При росте стоимости кредита предприятия с уже невысокой ликвидностью и слабой маржой первыми сталкиваются с проблемами обслуживания долга.

d. Общий объём кредитования компаний с ОКВЭД 24-25.

Объём кредитования по соответствующим кодам ОКВЭД отражает доступность банковского финансирования для металлургии и смежных отраслей. Рост объёма кредитования может свидетельствовать о доверии банков к отрасли, наличии новых инвестиционных проектов и поддержке текущей деятельности. В то же время, чрезмерный рост кредитования при буме может приводить к образованию пузыря, который в период спада трансформируется в повышенный уровень дефолтов. Включение этой переменной позволяет модели учесть не только стоимость, но и масштаб использования заёмного капитала в отрасли в разные периоды, что важно для оценки системного кредитного риска.

Вопрос мультиколлинеарности и отбора признаков: изначально предполагалось не использовать все доступные переменные в итоговой спецификации, а отобрать наиболее информативные признаки с точки зрения объяснения вероятности дефолта. Это связано с тем, что часть факторов потенциально сильно коррелирует между собой, особенно среди макроэкономических показателей.

6. Гипотезы исследования.

На основе проведённого обзора литературы были сформулированы гипотезы, которые описывают влияние различных факторов на вероятность дефолта корпоративных заемщиков металлургической отрасли.

- *Гипотеза 1.*

Финансовые показатели являются ключевыми детерминантами вероятности дефолта компаний металлургической отрасли.

Фирмы с более высокой прибыльностью (EBIT_L1, ROA_L1), низкой долговой нагрузкой (debt_equity_L1) и большей ликвидностью (current_liq_L1) имеют статистически значимо более низкую вероятность дефолта.

- *Гипотеза 2.*

Нефинансовые характеристики компании оказывают существенное влияние на вероятность дефолта.

Возраст компании (age), регион регистрации (region), организационно-правовая форма (form) и тип деятельности внутри отрасли (ttype, ОКВЭД 24-25) влияют на PD (более зрелые и структурно устойчивые компании имеют меньший риск дефолта, PD различается между регионами и подотраслями).

- *Гипотеза 3.*

Макроэкономическая конъюнктура является значимым внешним фактором, влияющим на вероятность дефолта металлургических компаний.

Улучшение деловой активности в экономике (рост PMI_L1) снижает вероятность дефолта, а ухудшение условий повышает PD.

II. Данные.

Данные о финансовых показателях компаний металлургического сектора взяты со СПАРКа. Из-за ограничения выгрузки в 10 000 строк выборка собиралась так, чтобы была возможность получить максимально большое количество наблюдений. Отдельно выгружаем действующие и ликвидированные компании по признаку статуса. Для всех компаний используются данные за 2020-2024 годы. Для ликвидированных компаний дополнительно отбирались только те, у которых ликвидация произошла не ранее 2021 года, чтобы можно было построить лаги финансовых показателей. Также на этапе формирования выборки отсекались компании моложе пяти лет.

Далее отдельно обрабатываются ликвидированные компании. Для каждого наблюдения в данных оставляется только год ликвидации и предшествующий ему год, чтобы в год ликвидации можно было использовать значения финансовых показателей с лагом. На основе даты ликвидации создаётся целевая переменная *def*, по умолчанию она равна нулю, а значение «1» присваивается наблюдениям, соответствующим году ликвидации и (при наличии) наблюдению за один год до ликвидации. Это позволяет количество положительного класса в выборке. Затем формируются лаги для всех

финансовых показателей: рассчитывается L1 по регистрационному номеру компании. Наблюдения, для которых отсутствуют все лагированные финансовые показатели, удаляются, поскольку такие строки не могут быть использованы при моделировании.

Далее вводится правило определения банкротства через долговую нагрузку и избавление от проблемы со знаками мультипликаторов. Поскольку среди ликвидированных компаний не было отчётов с отрицательным совокупным долгом, отрицательный Debt/Equity мог возникнуть только из-за отрицательного собственного капитала, поэтому мультипликатор Debt/Equity пересчитывается, как $10 + |\text{Debt/Equity}|$. Далее банкротами (в рамках сформированного набора ликвидированных) считаются те, у кого $\text{Debt/Equity} > 1$, и выборка дополнительно фильтруется по этому условию. Также выполняются специальные преобразования для ROE и ROA в ситуациях, когда база и прибыль/убыток принимают отрицательные значения (в коде это реализовано через переназначение значений по условиям с умножением на -1 и сдвигом на -10), чтобы «перевести» такие случаи в отдельную область значений и не смешивать их с обычными наблюдениями.

Затем аналогично подготавливаются действующие компании. Датасет обрабатывается аналогичным способом и приводится к формату «компания–год», после чего для всех наблюдений задаётся $\text{def} = 0$. По действующим компаниям также выполняются преобразования показателей долговой нагрузки и рентабельности.

Признак принадлежности к госсектору заполняется: пропуски заменяются на значение «нет». Дата ликвидации для действующих компаний заполняется символом прочерком, после чего для выполняется удаление оставшихся пропусков, и фиксируется итоговый размер выборки. Предположительно, в данных наблюдается сильный дисбаланс классов, так что удаление строк с пропусками лишь положительно скажется на качестве итоговой модели.

Переходим к сбору макрофакторов. PMI загружается через запросы к API Cbonds по месячным значениям за период 2020–2024, после чего агрегируется в среднегодовой показатель. Курс USD/RUB берётся из источника ЦБ РФ, затем также переводится в годовую частоту. После этого формируется таблица макроэкономических факторов, куда добавляются средние процентные ставки по кредитам до 1 года для обрабатываемого сектора (из отчета ЦБ) и общий объём кредитования по ОКВЭД 24–25 (также из отчета ЦБ). Для макропеременных дополнительно рассчитываются лаги

L1, и в финальной таблице остаются лагированные значения PMI, USD/RUB, ставок и объёма кредитования, строки без лагов удаляются.

На завершающем шаге склеиваются действующие и ликвидированные компании в один датасет, затем к нему по признаку «год наблюдения» присоединяются макрофакторы. В результате получаем финальный датасет с колонками: год, идентификаторы компании, категориальные признаки (регион, отрасль, организационно-правовая форма и признак госсектора), лагированные финансовые показатели и макрофакторы.

III. Предварительный анализ данных.

1. Проверка полноты данных и работа с пропусками.

Предобработка датасета включала проверку пропущенных данных у компаний (тех, где пропущено больше количество значений и работа с ними невозможна). Ликвидированным компаниям характерны пропуски для финансовых показателей (компания фактически не работает, поэтому капитала/прибыли может уже не быть). Построены диаграммы визуализации пропущенных значений для таких компаний. Для нашего датасета это EBIT, Чистая прибыль, ROA, ROE и коэффициенты ликвидности (рис. 2).




Рисунок 1. Матрица пропущенных значений.




Рисунок 2. Корреляционная матрица наличия пропущенных значений.

Заметим, что пропуски коррелируют между собой (рис. 3). Следовательно, пропуск в каком-либо финансовом показателе почти всегда означает полное отсутствие отчетности. Такие компании следует удалить из выборки, так как восстановление пропусков по нефинансовым признакам невозможно и приведет к сильному смещению.

Для оставшихся компаний точечные пропущенные значения были восстановлены на основе доступных финансовых показателей, используя метод KNN, так как он способен заполнить пропуски максимально приближенными значениями «соседей», подбирая более похожие компании, что снижает возможность искажения данных для ликвидированных компаний.

2. Доля дефолтных компаний.

Анализ распределения классов для модели оценки вероятности дефолта показывает дисбаланс: доля $def = 1$ составляет 3.76% от общего числа наблюдений (рис. 1), смещения выборки тут сложно избежать.




Рисунок 3. Распределение дефолтов.

3. Выбросы.

Рассмотрим изначальное распределение числовых признаков, используемых в нашем проекте:




Рисунок 4. Распределение числовых признаков с выбросами.

Заметим, что только возраст компаний имеет распределение, приближенное к нормальному (рис. 4). Остальные же переменные включают в себя выбросы, которые сильно влияют на распределение, перекашивая данные, что может привести к смещению модели.

Для работы с выбросами мы использовали метод квантильного отсечения: из выборки удалялись наблюдения, попадающие в крайние хвосты распределений ключевых финансовых показателей и коэффициентов. Для EBIT и чистой прибыли отсекались как нижние, так и верхние хвосты, для ROA/ROE и коэффициентов ликвидности также применялось двустороннее отсечение с асимметричными границами; для Debt/Equity ограничивался преимущественно верхний хвост, где концентрируются экстремальные значения.

Пороги отсеечения подбирались для каждого параметра:

- EBIT_L1: между 1-м и 95-м перцентилями
- net_profit_L1: между 1-м и 95-м перцентилями
- debt_equity_L1: не выше 96.5-го перцентиля
- ROA_L1: между 1.5-м и 98-м перцентилями
- ROE_L1: между 1-м и 99.3-м перцентилями
- quick_liq_L1: между 1-м и 98-м перцентилями
- current_liq_L1: между 1-м и 98-м перцентилями

Получаем итоговое распределение переменных:




Рисунок 5. Распределение числовых признаков без выбросов.

Для числовых факторов построены графики зависимости *default rate* от интервалов значений. Можем проверить, что признак адекватно описывается с точки зрения изменения *default rate* (адекватная интерпретация).




Рисунок 6. Default Rate по бинам числовых признаков.

Все признаки имеют логичное распределение среднего количества дефолтов по бинам (рис. 6).

4. Нефинансовые признаки.

В датасете представлено слишком много различных регионов, с преобладанием регистрации в Москве и Санкт-Петербурге (рис. 7).




Рисунок 7. Распределение наиболее популярных регионов.

Для удобства работы с данными и облегчения модели мы разбили регионы на основные блоки, используя информацию о координатах (рис. 8).




Рисунок 8. Разбиение регионов на географические квадраты.

Для более достижения равномерного распределения компаний по регионам блоки были объединены следующим образом:

- 0 – Юг;
- 5 – Москва;
- 10 и 15 - Русский Север;
- 11 и 6 – Урал;
- 12 и 7 – Центральная Россия;
- 3, 8, 9, 13 и 14 – Восток;

Таким образом, получили всего 6 крупных групп регионов, которые отражают инфраструктуру, близость соседних регионов, возможные цепочки поставок, которые важны в металлургической отрасли.

В датасете также указаны подотрасли – то, чем фактически занимается компания. Данный признак включает в себя 78 уникальных значений, многие из которых встречаются единожды (рис. 9).



Рисунок 9. Распределение наиболее популярных подотраслей.

Так как подотрасль задана текстовыми формулировками, естественно наличие множества уникальных значений, поэтому в исходном виде признак не удобен для анализа. Чтобы получить небольшой набор сопоставимых категорий, мы перевели текстовые описания в числовое представление на основе важности слов и словосочетаний, затем сжали это представление до компактного набора компонент, чтобы убрать шум и оставить основную смысловую структуру (использовали TF-IDF + SVD). Затем была обучена модель кластеризации KMeans. Количество кластеров было подобрано на основе максимизации расстояния между кластерами.

Получили шесть основных типов деятельности. Для интерпретации были построены облака слов, по которым были подобраны наиболее характерные слова и присвоены названия (рис. 10):

- «Разнородные металлические изделия»;
- «Металлоконструкции для строительства»;
- «Покрытия и обработка поверхностей»;
- «Инструмент и оснастка»;
- «Металлоизделия массового сегмента»;
- «Окна и двери».



Рисунок 10. Облака слов для составленных кластеров подотраслей.

По итогам обработки были построены графики распределения категориальных признаков, чтобы посмотреть их структуру, выявить, есть ли сильные перекосы в данных.




Рисунок 11. Распределение категориальных признаков.




Рисунок 12. Default Rate по категориям.

Заметим, что компании с государственным участием практически не представлены в выборке (рис. 11). А также Default Rate для государственных компаний выше, чем у частных (рис. 12). Чтобы не увеличивать смещение модели, было принято решение об исключении признака из модели. Основная юридическая форма регистрации фирмы – ООО, также встречаются АО (самые крупные компании в отрасли), ПАО – сильно реже (рис. 11). Поэтому остальные категории объединены как «Прочее». Однако оказалось, что в новой категории вообще нет банкротов, что не поддается логике (рис. 12). Скорее всего, это произошло из-за малого количества дефолтов в выборке в целом. Данную категорию стоит исключить из рассмотрения вообще и удалить соответствующие наблюдения.

IV. Отбор признаков.

После формирования итогового датасета создаётся целевая переменная y , соответствующая индикатору дефолта def . В качестве матрицы признаков X используется датасет, из которого исключаются целевая переменная и идентификационные поля, не предназначенные для обучения моделей.

Для предварительной оценки информативности признаков числовые переменные анализируются двумя способами. Во-первых, рассчитывается t -статистика, измеряющая нормированную разницу средних значений признака между дефолтными и недефолтными наблюдениями. Для этого выборка разбивается на два поднабора по значению целевой переменной, после чего для каждого числового признака считается абсолютная разность средних, нормированная на объединённую дисперсию с учётом размеров подвыборок. Во-вторых, для всех числовых признаков рассчитывается абсолютная корреляция с целевой переменной. Результаты обоих подходов визуализируются в виде тепловых карт и используются для качественной оценки связи признаков с дефолтом (рис. 13).




Рисунок 13. Корреляция признаков с таргетом и t -статистика.

Дополнительно проводится анализ мультиколлинеарности. Для этого все категориальные признаки кодируются дамми-переменными, после чего для расширенной матрицы признаков рассчитываются значения VIF.

Признаки с повышенными значениями VIF анализируются отдельно: для них строится корреляционная матрица, чтобы выявить источники линейной зависимости. П

По результатам, ожидаемо наблюдается высокая корреляция между макроэкономическими переменными и годом наблюдения, а также между отдельными парами финансовых показателей, такими как EBIT и чистая прибыль, ROA и ROE, коэффициенты быстрой и текущей ликвидности (рис. 14).




Рисунок 14. Корреляционная матрица признаков.

Все признаки кодируются WOE-преобразованием (логарифм доли положительного класса к доле отрицательного в бине). На основе этих преобразований посчитаны Information Value каждого признака. Среди коррелирующих между собой признаков оставлены переменные с наибольшим IV.

Итоговый набор признаков для обучения:

- Числовые: net_profit_L1, ROA_L1, debt_equity_L1, age, PMI_L1, current_liq_L1;
- Категориальные: region, ttype, form.

V. Train / Test split.

После этапа отбора признаков данные разделяются на обучающую, валидационную и тестовую выборки. Разделение проводится стратифицированно по целевой переменной y, чтобы сохранить одинаковую долю дефолтов в каждой части выборки. Сначала 20% наблюдений выделяются в тестовую выборку. Оставшиеся 80%

далее делятся на обучающую и валидационную части таким образом, что валидационная выборка составляет 15% от исходного датасета, а обучающая - оставшиеся наблюдения.

После разбиения проверяется размер каждой выборки и доля дефолтов в train, validation и test. Распределения целевой переменной в обучающей и тестовой выборках дополнительно визуализируются, что подтверждает сохранение исходного дисбаланса классов (рис. 15). Поскольку в данных наблюдается выраженный дисбаланс классов, дальнейшая работа с балансировкой проводится только на обучающей выборке. Для этого обучающая выборка разбивается на подмножества дефолтных и не дефолтных наблюдений. Задаётся целевое соотношение дефолтов на уровне 5%. На основании этого рассчитывается необходимое число недефолтных наблюдений, после чего из них случайным образом производится undersampling без возвращения. Дефолтные наблюдения сохраняются полностью. Полученные подвыборки объединяются, случайным образом перемешиваются, и формируется финальная сбалансированная обучающая выборка. Для неё дополнительно контролируются итоговый размер и фактическая доля дефолтов, которая соответствует заданному уровню.




Рисунок 14. Доля дефолтов в Train и Test выборках.

VI. Интерпретируемая модель.

Переходим к этапу построения моделей. Сначала обучим логистическую регрессию поверх WOE-преобразований наших признаков. Логистическая регрессия является интерпретируемой моделью. Мы можем проверить поставленные гипотезы, исходя из оценок коэффициентов. При соблюдении предпосылок теоремы Гаусса-Маркова (некоррелированность регрессоров со случайной ошибкой, гомоскедастичность и др.) оценки являются несмещенными и состоятельными, то есть, влияние переменных на таргет в действительности является таким, как показывают коэффициенты. Конечно, предпосылки часто нарушаются, но мы будем использовать робастные ошибки, чтобы избежать большинство нарушений.

Результаты оценки модели:

Признак	Коэфф.	Значимость
Const	-3.645	***
WOE_age	-1.162	***
WOE_net_profit_L1	-0.550	***
WOE_debt_equity_L1	-1.233	***
WOE_ROA_L1	-0.201	
WOE_current_liq_L1	-0.319	***
WOE_global_region	-1.070	***
WOE_form	-1.221	
WOE_PMI_L1	-0.744	***
WOE_cluster_ttype	-0.246	

Таблица 1. Оценки коэффициентов LR и их значимость.

Интерпретация результатов:

- Все значимые коэффициенты отрицательные. Рост WOE по признаку снижает вероятность дефолта.
- Самые сильные и значимые факторы: WOE_debt_equity_L1, WOE_age, WOE_global_region.
- WOE_net_profit_L1 и WOE_PMI_L1 значимы и тоже снижают риск при росте WOE.
- WOE_current_liq_L1 значим, эффект умеренный, рост WOE снижает риск.

- WOE_ROA_L1 незначим, в этой спецификации его вклад статистически не подтвержден. Возможно, константа забрала на себя влияние признака.
- WOE_form и WOE_cluster_ttype незначимы, их влияние неустойчиво.
- Константа отрицательная, базовый уровень вероятности дефолта низкий при нулевых WOE.

Логистическая регрессия моделирует вероятность события через логарифм отношения шансов "Odds":

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \beta_0 + \sum_j \beta_j \cdot \text{WOE}_j$$

Чтобы не работать с коэффициентами и логарифмом шансов, строят скоринговую карту. Каждому WOE-бину присваивается некоторый балл, а сумма всех баллов является итоговой оценкой. Для этого вводятся переменные:

- PDO - количество баллов, при котором Odds удваивается - полезно, чтобы оценка менялась на фиксированное число;
- Базовый балл - константа, изначальное значение оценки.

Балл для каждого WOE-бина рассчитывается по формуле:

$$\text{Score} = -\beta_j \cdot \text{WOE}_j \cdot \frac{\text{PDO}}{\ln 2}$$

Перед коэффициентом стоит знак "минус", чтобы соблюсти правило - чем выше риск, тем меньше балл.

Итоговая скоринговая карта:

Переменная	Бин	Балл
Intercept		103
age	(-inf, 9.5)	-11
age	(9.5, inf)	8
net_profit_L1	(-inf, 4 500)	-21
net_profit_L1	(4 500, 289 500)	3
net_profit_L1	(289 500, 864 500)	18
net_profit_L1	(864 500, 3 159 500)	22
net_profit_L1	(3 159 500, inf)	27
debt_equity_L1	(-inf, 1.01)	3

debt_equity_L1	(1.01, 2.19)	-5
debt_equity_L1	(2.19, 6.90)	-8
debt_equity_L1	(6.90, inf)	-42
ROA_L1	(-inf, 0.00305)	-7
ROA_L1	(0.00305, 0.02565)	3
ROA_L1	(0.02565, inf)	7
current_liq_L1	(-inf, 0.83)	-9
current_liq_L1	(0.83, 1.05)	-4
current_liq_L1	(1.05, 1.37)	3
current_liq_L1	(1.37, 2.13)	7
current_liq_L1	(2.13, inf)	11
global_region	Восток	-16
global_region	Москва	4
global_region	Север	-4
global_region	Урал	4
global_region	Центр	-7
global_region	Юг	-14
form	АО	-3
form	ООО	0
form	ПАО	-3
PMI_L1	45.98	-4
PMI_L1	50.31	-3
PMI_L1	50.44	0
PMI_L1	53.30	12
cluster_ttype	Инструмент и оснастка	0
cluster_ttype	Металлоизделия массового сегмента	-1
cluster_ttype	Металлоконструкции для строительства	0
cluster_ttype	Окна и двери	1

cluster_ttype	Покрытия и обработка поверхностей	0
cluster_ttype	Разнородные металлические изделия	1

Таблица 2. Скоринговая карта.

Балл отражает вклад признака в кредитный риск: положительный балл снижает риск дефолта, отрицательный балл повышает риск.

- Наибольшее влияние оказывает debt_equity_L1: высокая долговая нагрузка приводит к максимальному штрафу по баллам, низкая ведет к бонусу.
- Признаки net_profit_L1 и ROA_L1 формируют устойчивый положительный вклад: рост прибыльности и рентабельности повышает итоговый скор.
- Признаки current_liq_L1 влияет умеренно: низкая ликвидность увеличивает риск, высокая — снижает.
- Более старые компании получают положительные баллы.
- Отдельные регионы систематически ухудшают или улучшают оценку.
- PMI_L1 учитывает макроэкономическую фазу: высокий PMI повышает скор, низкий -снижает.
- Организационно-правовая форма и подотрасль имеют минимальный вклад.

Оценки коэффициентов и поставленные баллы подтверждают поставленные в начале исследования гипотезы. Финансовые показатели действительно оказывают наибольшее влияние на формирование оценки вероятности дефолта, однако возраст компании, регион и ОПФ совместно так же вносят свой вклад. Макроэкономическая ситуация так же отражается на дефолтности отрасли, имеет статистически значимое влияние.

Перейдем к оценке предиктивной способности построенной модели. Здесь и далее мы будем использовать метрики AUC-ROC (вероятность того, что оценка модели случайно взятого объекта положительного класса будет выше оценки случайного объекта отрицательного класса), AUC-PR (площадь под кривыми Precision – точность – и Recall – полнота покрытия положительного класса, баланс между убытками и

упущенной выручкой), и коэффициент Джини (наиболее часто используемая метрика в кредитном скоринге, разделительная способность от 0 до 1).

Итак, подберем параметр регуляризации, чтобы не допустить переобучение, и посчитаем наши метрики.




Рисунок 15. Визуализация метрик качества LR.

Итоговое качество модели:

AUC-PR	AUC-ROC	Gini
0.12	0.82	0.64

Таблица 3. Метрики качества LR.

Все три метрики качества имеют достаточно низкие значения (таблица 3). Как обсуждалось ранее, наши признаки практически не отражают линейной связи с целевой переменной. А значит, линейная модель логистической регрессии, не способна поймать эти связи.

VII. Не интерпретируемая модель.

С целью повышения качества перейдем к алгоритмам, способным искать и моделировать нелинейные связи признаков и вероятности банкротства. В таком случае мы жертвуем интерпретируемостью модели. Рассмотрим три наиболее часто применяемых алгоритма классического машинного обучения:

- Градиентный бустинг – ансамбль деревьев решений, направленный на снижение смещения ошибки. Каждое последующее дерево учится уменьшать ошибки предыдущих с помощью градиентного спуска.
- Случайный лес – ансамбль деревьев решений, направленный на снижение дисперсии ошибки. Каждое дерево обучается на разных бутстрапированных подмножествах обучающей выборки. Прогноз отдельного наблюдения получается путем усреднения прогнозов всех деревьев.
- Support Vector Machine – максимизация расстояния наблюдений от разделяющей гиперплоскости. По умолчанию SVM является линейной моделью, то есть, качество может не сильно повыситься в сравнении с логистической регрессией. Однако, используя ядровой переход, мы можем преобразовать наши признаки и обучить модель в новом спрямляющем пространстве, в котором объекты линейно разделимы. Мы будем использовать RBF (Гауссово) ядро.

Перед началом обучения следует обработать должным образом наши признаки. Числовые переменные мы отмасштабируем с помощью `StandardScaler`, чтобы разные масштабы не мешали регуляризации. Категориальные признаки закодируем `MeanTargetEncoder`-ом – среднее значение целевой переменной в категории. Также пробовали создавать множество дамми-переменных с помощью `OneHotEncoder`-а, но качество от этого только снизилось.

1. Градиентный бустинг.

После обработки признаков запустим поиск гиперпараметров регуляризации (максимальная глубина, количество листов; минимальное количество наблюдений в отдельном листе и др.) на валидационной выборке с помощью `Optuna` (Байесовская оптимизация). После подбора экзогенных параметров, наконец, обучим модель и посчитаем метрики на тестовой выборке. Пробовали различные реализации

градиентного бустинга от разных разработчиков (Xgboost, LightGBM). Лучшее качество показывает CatBoost от Яндекса.




Рисунок 16. Визуализация метрик качества CatBoost.

Итоговое качество модели:

AUC-PR	AUC-ROC	Gini
0.23	0.88	0.77

Таблица 4. Метрики качества CatBoost.

Градиентный бустинг показывает значительное повышение качества, как по точности и покрытию, так и по разделяющей способности модели (таб. 4).

2. Случайный лес.

Аналогично подбираем гиперпараметры, обучаем модель (RandomForest от sklearn) и считаем метрики.




Рисунок 17. Визуализация метрик качества RandomForest.

Итоговое качество модели:


AUC-PR	AUC-ROC	Gini
0.2	0.87	0.74

Таблица 5. Метрики качества CatBoost.

По всем трем метрикам качества случайный лес так же превосходит в разы показатели логистической регрессии, однако модель уступает результатам градиентного бустинга (таб. 5). Снижения дисперсии ошибки оказалось недостаточно.

3. *SVM + RBF*

Наконец, обучим ядровый SVM, так же предварительно подобрав коэффициенты регуляризации и Гауссова ядра.






Рисунок 18. Визуализация метрик качества SVM + RBF.

Итоговое качество модели:

AUC-PR	AUC-ROC	Gini
0.15	0.76	0.52

Таблица 6. Метрики качества SVM + RBF.

Разделяющая способность ядрового SVM оказалась даже ниже логистической регрессии (таб. 6). Однако точность и покрытие выше. Алгоритм проигрывает по всем метрикам и случайному лесу, и градиентному бустингу.

VIII. Валидация.

Итак, наилучшей моделью по всем метрикам качества оказался градиентный бустинг в реализации CatBoost. Посмотрим, какие признаки вносят вклад в формирование оценки вероятности дефолта.




Рисунок 19. Вклад Gini признаков в модель.

Как видно на графике, наибольшей разделяющей способностью так же обладают финансовые показатели (долговая нагрузка, чистая прибыль, ROA, текущая

ликвидность) (рис. 19). Модель получилась весьма интерпретируемой. Возраст компании, РМІ, регион регистрации, подотрасль и ОПФ так же вносят свой вклад, но он значительно ниже в сравнении с вкладом финансовых признаков.

Осталось выбрать порог отсечения, при превышении которого мы будем отказывать компании в кредитовании. Порог выбирается путем оптимизации бизнес-метрик. В нашем случае мы будем максимизировать упрощенную прибыль. Будем считать, что выдаем кредит на один год, в качестве тела кредита возьмем общие долги компании в текущем году, выдаем кредит под 20% годовых. Долю потерь от общего долга по клиенту определим фиксированно – 70%.

Если кредит выплачен $y = 0$, то прибыль составляет:

$$\pi_i = Debt_i \cdot r$$

Если кредит не выплачен, то убытки составляют:

$$\pi_i = -LGD_i \cdot Debt_i$$

Суммарная прибыль вычисляется по формуле:

$$\pi(t) = \sum_{i:p_i < t} [(1 - y_i) \cdot Debt_i \cdot r - y_i \cdot Debt_i]$$

Будем перебирать порог $t \in 0, 1$ с шагом 0.05.




Рисунок 20. Прибыль от кредитования.

Оптимальный порог - $t \approx 0.47$. Суммарная прибыль по историческим данным составила приблизительно 8.3 миллиарда рублей (рис. 20).

Построим матрицу ошибок.




Рисунок 21. Матрица ошибок.

Модель получилась весьма консервативной (рис. 21). Банк скорее упустит выгоду, чем выдаст кредит клиенту – будущему банкроту.

IX. Заключение.

В рамках данного исследования был проведен полный цикл построения модели кредитного скоринга для оценки вероятности дефолта компаний металлургического сектора. Был проведен анализ особенности отрасли, были изучены предыдущие исследования по данной теме. На основе литературного обзора были отобраны признаки для построения модели и выведены гипотезы для анализа.

Для обучения модели были собраны финансовые, нефинансовые и макроэкономические факторы из различных источников. На этапе предварительного анализа были восстановлены пропущенные значения, исключены выбросы, предобработаны числовые и категориальные признаки.

Удалось построить две модели: интерпретируемая статистическая модель логистической регрессии, на основе которой были проверены и подтверждены поставленные в начале исследования гипотезы, и не интерпретируемая модель градиентного бустинга, основной целью которой являлось повышение качества ранжирования.

Проведена валидация модели, посчитан вклад каждого признака, подобран порог отсечения, максимизирующий прибыль от кредитования.

Построенная модель может использоваться банками для оценки вероятности дефолта компаний металлургического сектора. Она имеет достаточно высокое качества точности, покрытия и разделяющей способности, исходя из посчитанных метрик

качества. Однако оценки модели в любом случае должны утверждаться кредитными экспертами, особенно, когда речь идет о кредитовании крупных корпораций большими объемами.

В дальнейшем можно улучшать качество модели путем увеличения количества наблюдений положительного класса, а также, используя модели Deep Learning'a (нейронные сети).

Источники.

1. World Steel Association. World Steel in Figures 2025 : электронный ресурс. URL: <https://worldsteel.org/data/world-steel-in-figures/world-steel-in-figures-2025/> (дата обращения: 14.12.2025).
2. S&P Global. Russia Manufacturing PMI (Press Release) : электронный ресурс. URL: <https://www.pmi.spglobal.com/Public/Home/PressRelease/> (дата обращения: 14.12.2025).
3. Bondarkov S. et al. Russian Financial Statements Database: A firm-level collection of the universe of financial statements (2011–2023) // Scientific Data. 2025 : электронный ресурс. URL: <https://www.nature.com/articles/s41597-025-05150-1> (дата обращения: 14.12.2025).
4. RFSD (Russian Financial Statements Database). Dataset Card / README : электронный ресурс. URL: <https://huggingface.co/datasets/irlspbru/RFSD> (дата обращения: 14.12.2025).
5. Коммерсантъ. Материалы о влиянии санкций и изменений логистики на металлургическую отрасль : электронный ресурс. URL: <https://www.kommersant.ru/> (дата обращения: 14.12.2025).
6. РБК. Публикации по металлургии и мерам поддержки отрасли : электронный ресурс. URL: <https://www.rbc.ru/> (дата обращения: 14.12.2025).
7. Berikova O.A., Zubarev A.V. Econometric Analysis of Bankruptcy Factors for Russian Companies in the Manufacturing Industry // MPRA Paper. 2022. No. 114969. URL: <https://mpra.ub.uni-muenchen.de/114969/> (дата обращения: 14.12.2025).
8. Shevelev I. Probability of Default Model Using Transactional Data of Russian Companies //

Working Paper. Bank of Russia. 2022. No. 97.

URL: https://www.cbr.ru/statichtml/file/138734/wp_97.pdf (дата обращения: 14.12.2025).

9. Тотьянина К.М.

Моделирование вероятности дефолта корпоративных заемщиков с учётом макроэкономической конъюнктуры //

Корпоративные финансы. 2014. № 4 (52).

URL: <https://cfjournal.hse.ru/article/view/1494/2146> (дата обращения: 14.12.2025).

10. Kabundi A.

Causes and Consequences of Industrial Commodity Price Shocks. World Bank, 2022.

URL: <https://thedocs.worldbank.org/en/doc/b4ff84b2d5dc4d0963a5074102460cc1-0350012022/related/Commodity-Markets-Chapter-4.pdf> (дата обращения: 14.12.2025).